Projet 6 :Optimisez la gestion & nettoyez les données du stock d'une boutique

Introduction

Aujourd’hui est un grand jour, je commence ma mission en tant qu’analyste chez BottleNeck, un marchand de vin prestigieux.

Nicolas, mon manager sur cette mission m’accueille chaleureusement et me propose de partager un café avec le reste de l’équipe du service.

Ce projet se divise en deux phases :

Agrégation des données : Regrouper et organiser les différentes sources d'information (extractions de l'ERP, site web, table de liaison) afin d'assurer leur cohérence.

Analyse approfondie : Identifier les erreurs de saisie et de prix, calculer le chiffre d'affaires, évaluer la marge et la rotation des stocks, et détecter les corrélations entre les indicateurs financiers et commerciaux.

Importation des librairies et chargement des fichiers

1.1 - Importation des librairies

```
#Importation de la librairie Pandas
import pandas as pd
```

```
#Importation de la librairie plotly
import matplotlib.pyplot as plt
import plotly.express as px
```

```
#Importation de la librairie numpy
import numpy as np
```

```
#Importation de la librairie seaborn
import seaborn as sns
```

1.2 - Chargements des fichiers

```
#Importation du fichier web.xlsx
web = pd.read_excel("web.xlsx")
#Importation du fichier erp.xlsx
erp = pd.read_excel("erp.xlsx")
#importation du fichier liaison.xlsx
liaison = pd.read_excel("liaison.xlsx")
```

Analyse exploratoire des fichiers

2.1 - Analyse exploratoire du fichier erp.xlsx

```
#Afficher les dimensions du dataset
print("Le tableau comporte {} observation(s) ou article(s)".format(erp.shape[0]))
print("Le tableau comporte {} colonne(s)".format(erp.shape[1]))
```

```
Le tableau comporte 825 observation(s) ou article(s)
Le tableau comporte 6 colonne(s)
```

```
#Consulter le nombre de colonnes
#La nature des données dans chacune des colonnes
#Le nombre de valeurs présentes dans chacune des colonnes
erp.info(())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 825 entries, 0 to 824
Data columns (total 6 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   product_id      825 non-null    int64
 1   onsale_web      825 non-null    int64
 2   price           825 non-null    float64
 3   stock_quantity  825 non-null    int64
 4   stock_status    825 non-null    object
 5   purchase_price  825 non-null    float64
dtypes: float64(2), int64(3), object(1)
memory usage: 38.8+ KB
```

```python
#Vérifier si il y a les lignes en doublons dans la colonne product_id
#création d'une fonction pour trouver la clé primaire afin d'éviter de faire plusieurs fois la même chose#
def cle(df,colonne):
    if df.size== df.drop_duplicates(colonne).size:
        print ("colonne unique et donc une clé potentielle")
    else:
        print ("doublons donc la colonne n'est pas une clé")
```

```python
#Vérifier si il y a les lignes en doublons dans la colonne product_id
cle(erp,['product_id'])
```

```
colonne unique et donc une clé potentielle
```

2.1.1.1 - Analyse de la variable PRIX

```
erp.describe(())
```

	product_id	onsale_web	price	stock_quantity	purchase_price
count	825.000000	825.000000	825.000000	825.000000	825.000000
mean	5162.597576	0.867879	32.187697	21.589091	16.940582
std	902.644635	0.338828	26.712077	21.933807	14.561840
min	3847.000000	0.000000	-20.000000	-10.000000	2.740000
50%	4907.000000	1.000000	24.300000	18.000000	12.710000
max	7338.000000	1.000000	225.000000	145.000000	137.810000

```
erp.loc[erp['price']<=0,:]#supprimer les prix negatifs#
#il y a 3 produit avec des prix négatifs mais vu que dans la plupart des lignes , purchase_price est la moitié de price
```

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	stock_status_2
151	4233	0	-20.0	0	outofstock	10.33	outofstock
469	5017	0	-8.0	0	outofstock	4.34	outofstock
739	6594	0	-9.1	19	instock	4.61	instock

```
erp = erp[~erp["product_id"].isin([4233, 5017, 6594])]
```

2.1.1.2 - Analyse de la variable STOCK ¶

```
#######################
### stock_quantity  ###
#######################

#Affichier les stocks inférieurs à 0 (qu'est ce qu'il faut en faire ?)
erp.loc[erp['stock_quantity']<0,:]
```

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	stock_status_2
449	4973	0	10.0	-10	outofstock	4.96	instock
573	5700	1	44.5	-1	outofstock	22.30	instock

```
erp.loc[erp["product_id"].isin([4973, 5700]), "stock_quantity"] = 0
```

Pour la 1ere ligne on va la supprimer et pour la 2eme on va en parler a la team concernée et à mon niveau je vais mettre stock_quantity = 0

La colonne onsale_web indique si le produit est vendu sur le site ou non

2.2 - Analyse exploratoire du fichier web.xlsx

Il ya 2 lignes en moins dans la colonne sku, il faut comprendre pourquoi

```
cle(web,['sku'])
#ici visiblement nous devons comprendre pourquoi dans l'état actuel, cette colonne n'est pas conforme à un clé primaire#
```

```
doublons donc la colonne n'est pas une clé
```

```
#Recherche de ces 2 colonnes et placement dans une variable#
sku_null = web.loc[(web['sku'].isnull()) & (web['post_author'].notnull())]
sku_null
```

	sku	average_rating	total_sales	tax_status	tax_class	post_author	post_date	post_date_gmt	post_content	product_type	post_title	post_excerpt
1084	NaN	0.0	-56.0	taxable	NaN	2.0	2018-08-08 11:23:43	2018-08-08 09:23:43	NaN	Vin	Pierre Jean Villa Condrieu Jardin Suspendu 2018	Le nez séduit par ses parf...
1087	NaN	0.0	-17.0	taxable	NaN	2.0	2018-07-31 12:07:23	2018-07-31 10:07:23	NaN	Vin	Pierre Jean Villa Côte Rôtie Fongeant 2017	Fongeant 2017 explose sur un fruit brillant, p...

```
web.loc[web['post_name']=='pierre-jean-villa-condrieu-suspendu-2018',:]
```

	sku	average_rating	total_sales	tax_status	tax_class	post_author	post_date	post_date_gmt	post_content	product_type	post_title	post_excerpt
1084	NaN	0.0	-56.0	taxable	NaN	2.0	2018-08-08 11:23:43	2018-08-08 09:23:43	NaN	Vin	Pierre Jean Villa Condrieu Jardin Suspendu 2018	Le nez séduit par ses parf...

Visiblement il s'agit d'une erreur, il faut donc en discuter avec le manager ou les responsables produits afin de connaitre ces skus.

```python
web['sku'].unique().size
#exactement toutes les lignes avec un doubles des sku#
```

714

```python
#on retire donc les lignes qui représente des images afin de ne garder que les produits#
web = web.loc[web['post_type']=='product',:]
web
```

	sku	average_rating	total_sales	tax_status	tax_class	post_author	post_date	post_date_gmt	post_content	product_type	post_title	post_exc
2	14692	0.0	5.0	taxable	NaN	2.0	2019-03-19 10:06:47	2019-03-19 09:06:47	NaN	Vin	Château Fonréaud Bordeaux Blanc Le Cygne 2016	Grâce complément des 3 cépag
4	15328	0.0	2.0	taxable	NaN	2.0	2019-03-27 18:05:09	2019-03-27 17:05:09	NaN	Vin	Agnès Levet Côte Rôtie Maestria 2017	<span style="f none; backgro color
6	16515	0.0	10.0	taxable	NaN	2.0	2018-06-02 09:31:31	2018-06-02 07:31:31	NaN	Vin	Château Turcaud Bordeaux Rouge Cuvée Majeure 2018	id="wrapper">\r id="conta wrap

Jonction des fichiers

```
#j'utilise le dataframe "jointure" contenant "liaison" pour faire une jointure avec le dataframe web
jointure= pd.merge(jointure,web, left_on = 'id_web', right_on= 'sku', how= 'outer',indicator= True)
jointure
```

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	id_web	sku	average_rating	total_sales	...
0	3847	1.0	24.2	16.0	instock	12.88	15298	15298	0.0	6.0	...
1	3849	1.0	34.3	10.0	instock	17.54	15296	15296	0.0	9.0	...

```
jointure['_merge'].value_counts()
#on regarde à quoi correspondent ces 111 lignes#
```

```
_merge
both          714
left_only     111
right_only      0
Name: count, dtype: int64
```

on regarde à quoi correspondent ces 111 lignes

```
analys= jointure.loc[jointure['_merge']=='left_only',:]
analys
```

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price
19	4055	0.0	86.1	0.0	outofstock	37.88
20	4090	0.0	73.0	0.0	outofstock	33.79
21	4092	0.0	47.0	0.0	outofstock	25.25

On suppose que ces 111 produits ne sont pas proposés sur le site

Analyse univarié des prix

Etape 4.1 - Exploration par la visualisation de données

```
#Création d'une Boite à moustache de la répartition des prix grâce à Plotly
jointure.boxplot(column="price", vert=False )
plt.title("Graphique en boite à moustache des prix des bouteilles")
plt.show()
```

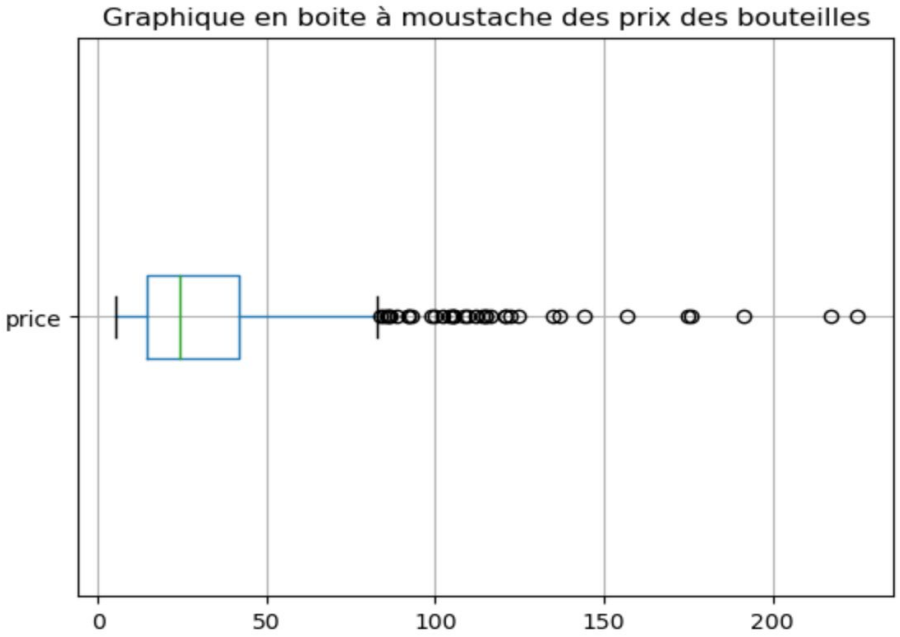

Etape 4.2.1 - Identification par le Z-index

```
#détermination des outliers avec le Z-score#
seuil= 2
std=np.std(jointure.price)
moyenne= np.mean(jointure.price)
#on vérifie que le z-core est au dessus du seuil#
outliers_zscore = [i for i in jointure.price if (i-moyenne)/std > seuil]
print(outliers_zscore)
```

```
[86.1, 144.0, 92.0, 100.0, 88.4, 225.0, 85.6, 176.0, 108.5, 157.0, 104.0, 109.6, 102.3, 137.0, 217.5, 105.0,
8, 92.0, 124.8, 175.0, 191.3, 93.0, 122.0, 114.0, 135.0, 105.6, 116.4, 115.0, 121.0, 99.0, 115.0, 121.0]
```

```
len(outliers_zscore)
```

```
34
```

Etape 4.2.2 - Identification par l'interval interquartile

```
Q1= jointure.price.quantile(0.25)
Q3= jointure.price.quantile(0.75)
IQ= Q3-Q1
```

En utilisant l'IQR, les points de données aberrants sont ceux qui se situent en dessous de Q1–1,5 IQR ou au-dessus de Q3 + 1,5 IQR. Le Q1 est le 25e centile et le Q3 est le 75e centile de l'ensemble de données, et l'IQR représente l'intervalle interquartile calculé par Q3 moins Q1 (Q3-Q1)

```
jointure[jointure.price < Q1-1.5*IQ]['price']
```

```
Series([], Name: price, dtype: float64)
```

```
df_outliersup = jointure[jointure.price > Q3+1.5*IQ][['product_id','price','post_title']]
```

Il y'a 32 outliers

Analyse univarié du CA, des quantités vendues, des stocks et de la marge ainsi qu'une analyse multivarié

```
#on fait la somme de cette colonne#
vente_totale= jointure['vente totale'].sum()
print("{:,.2f}".format(vente_totale) ,"€")
```

```
143,680.10 €
```

On distingue clairement une boisson qui contribue grandement au chiffre d'affaires

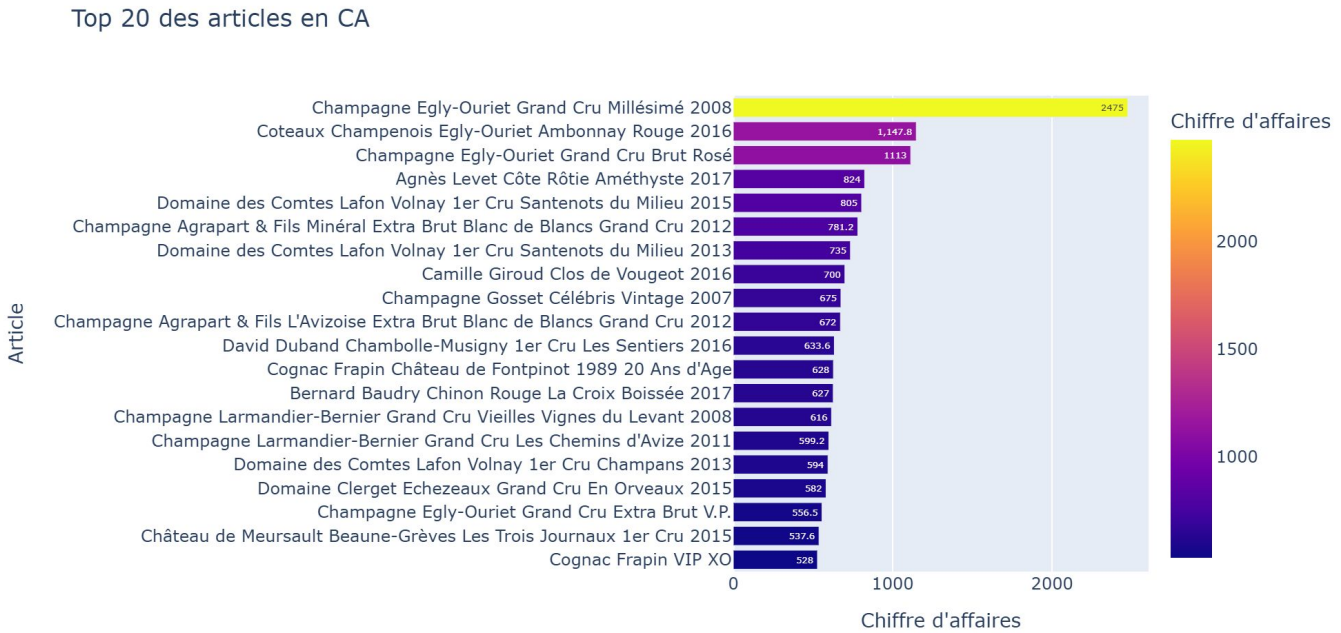

```python
##############################
# Calculer le 20 / 80 en CA #
##############################

#Créer une colonne calculant la part du CA de la ligne dans le dataset
df_merge["part_CA"] = df_merge["vente totale"] / df_merge["vente totale"].sum()

#Créer une colonne réalisant la somme cumulative de la colonne précedemment créée
df_merge["cumul_CA"] = df_merge["part_CA"].cumsum()

#Grâce au deux colonnes créées précedemment, calculer le nombre d'articles représentant 80% du CA
nb_articles_80 = df_merge[df_merge["cumul_CA"] <= 0.80].shape[0]
print(f"Nombre d'articles représentant 80% du CA : {nb_articles_80}")
```

```
Nombre d'articles représentant 80% du CA : 434
```

```python
print(f"Nombre d'articles total est : {df_merge.shape[0]}")
```

```
Nombre d'articles total est : 825
```

```python
#Afficher la proportion que représentent ce groupe d'articles dans le catalogue entier du site web
proportion_catalogue = nb_articles_80 / df_merge.shape[0] * 100
print(f"Ces articles représentent {proportion_catalogue:.2f}% du catalogue total.")
```

```
Ces articles représentent 52.61% du catalogue total.
```

Etape 5.2 - Analyse des ventes en Quantités

Il y a une boisson qui est nettement plus populaire que les autres et qui se vend en grandes quantités

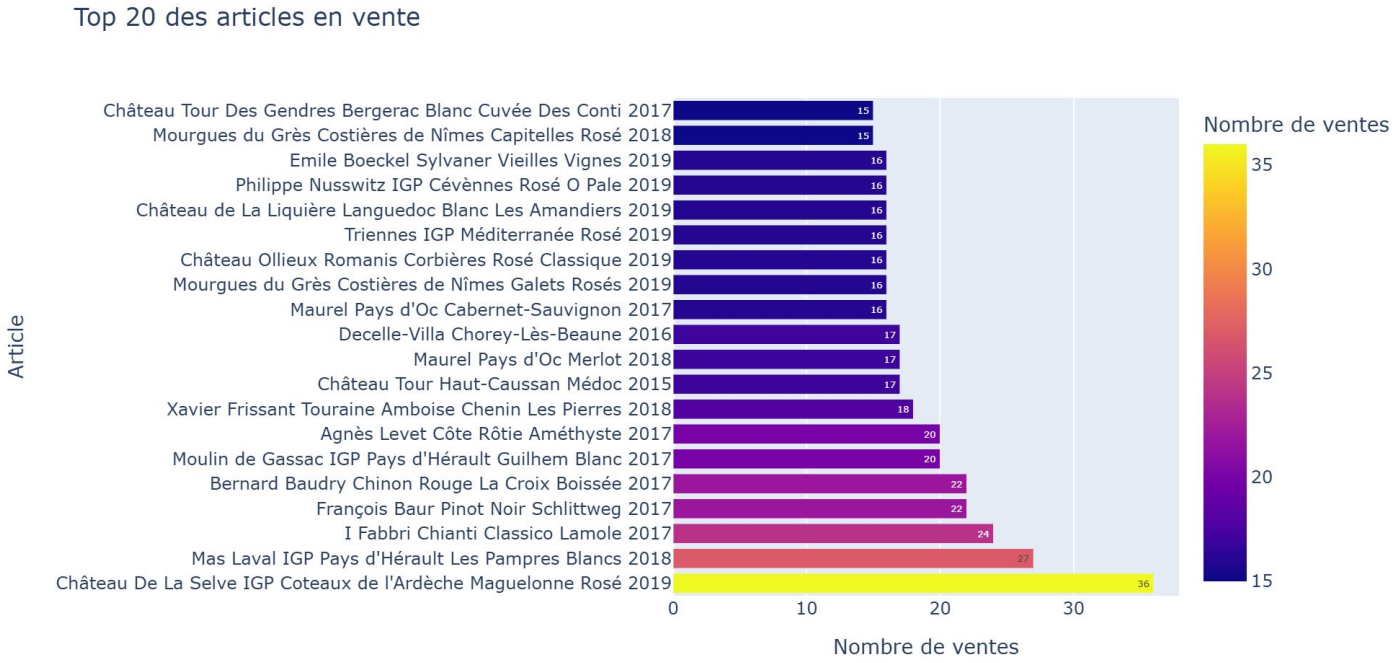

```python
############################
# Calculer le 20 / 80 en CA #
############################

#Créer une colonne calculant la part en quantité de la ligne dans le dataset
df_quantites.sort_values('total_sales', ascending= False, inplace= True)

#Créer une colonne réalisant la somme cumulative de la colonne précedemment créée
df_quantites["cumul_ventes"] = df_quantites["total_sales"].cumsum()
df_quantites["cumul_pourcentage"] =df_quantites["cumul_ventes"] / df_quantites["total_sales"].sum()
df_quantites.reset_index(drop= True, inplace= True)
```

```python
#Grâce au deux colonnes créées précedemment, calculer le nombre d'articles représentant 80% des ventes en quantité
nb_article_80 = df_quantites[df_quantites["cumul_pourcentage"] <= 0.80].shape[0]
print(f"Nombre d'articles représentant 80% des ventes en quantité : {nb_article_80}")
```

```
Nombre d'articles représentant 80% des ventes en quantité : 433
```

```python
df_quantites.sort_values('total_sales', ascending= False, inplace= True)
```

```python
#Afficher la proportion que représentent ce groupe d'articles dans le catalogue entier du site web
proportions_catalogue = nb_article_80 / df_quantites.shape[0] * 100
print(f"Ces articles représentent {proportions_catalogue:.2f}% du catalogue total.")
```

```
Ces articles représentent 52.48% du catalogue total.
```

Etape 5.3 - Analyse des stocks

Top 20 des produits ayant le plus de mois de stock

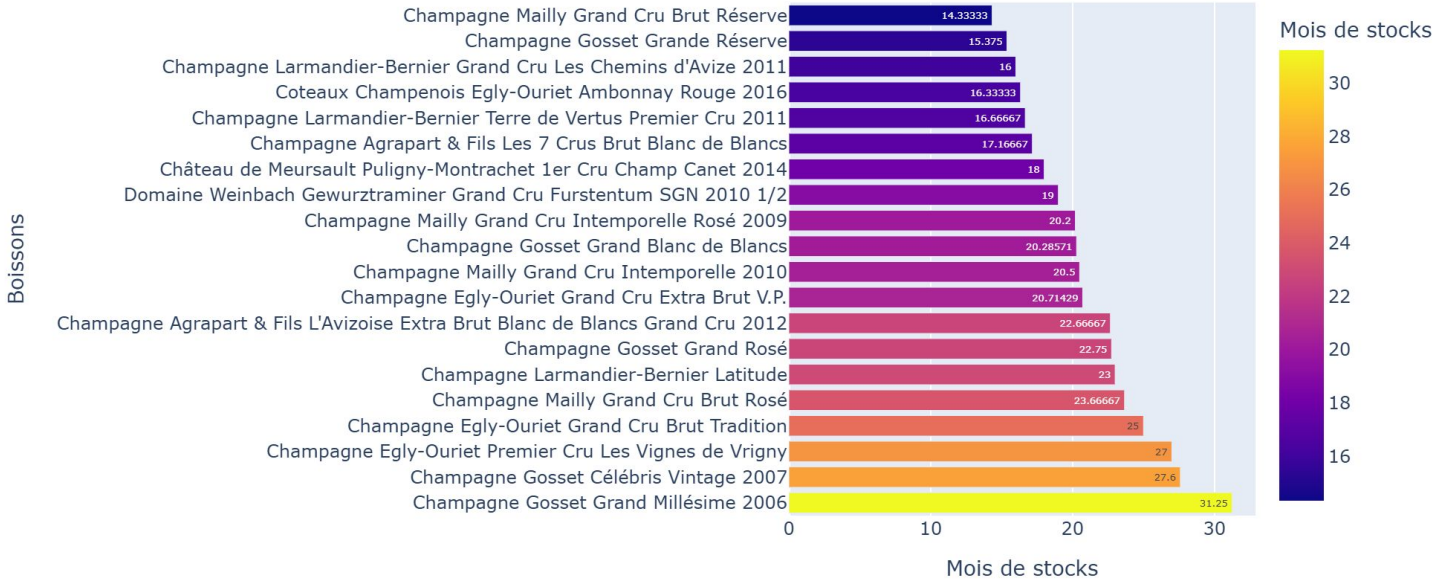

Ici on peut y voir un excès de stocks sur des produits qui n'ont pas beaucoup de demande.

Avoir trop de stocks immobilise des ressources financières qui pourraient être utilisées ailleurs dans l'entreprise.

```
#####################################
# Valorisation des stocks en euros #
#####################################

#Création de la colonne Valorisation des stocks en euros
df_merge["Valorisation_stock_euros"] = df_merge["stock_quantity"] * df_merge["price"]

#Calculer la somme de la colonne "Valorisation_stock_euros"
total_valorisation_stock = df_merge["Valorisation_stock_euros"].sum()
print(f"Valorisation totale des stocks : {total_valorisation_stock:.2f} €")
```

```
Valorisation totale des stocks : 531946.20 €
```

Le nombre total de produits en stock est 17803

Etape 5.4 - Analyse du taux de marge

```
#Création de la colonne prix HT
df_merge["prix_HT"] = df_merge["price"] / 1.2  # Supposons une TVA de 20%

#Création de la colonne Taux de marge
df_merge["taux_marge"] = (df_merge["prix_HT"] - df_merge["purchase_price"]) / df_merge["purchase_price"]
```

```
Le taux de marge minimum est de -86.39%
Le taux de marge maximum est de 91.41%
```

Il y a 4 produits qui contribuent aux taux de marge négatif, lorsqu'on ne les prend pas en compte, le taux de marge minimal est de 29.5%

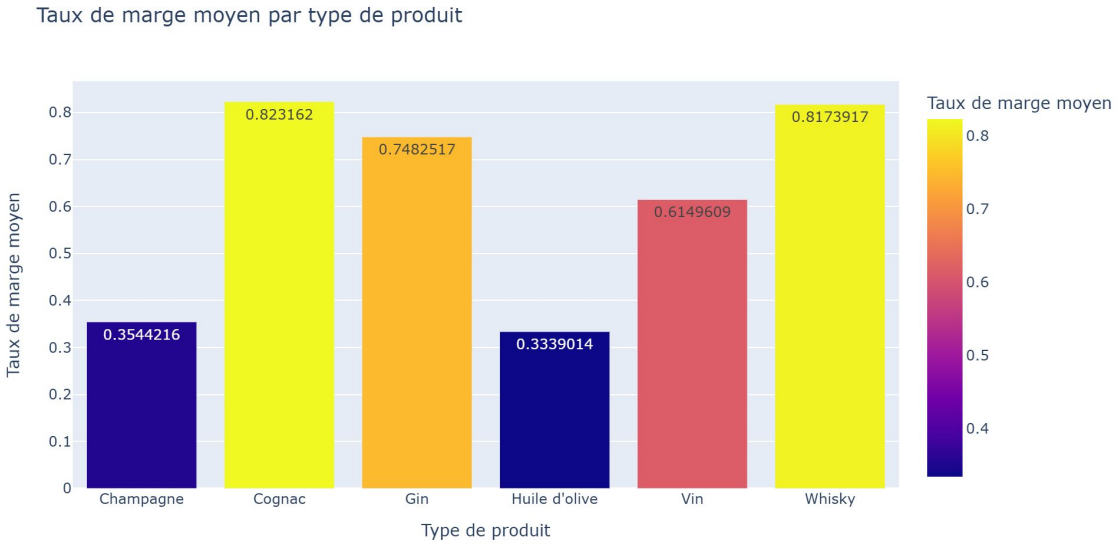

Etape 5.5 - Analyse des correlations entre les variables stock, sales et price

Stock & ventes : Une corrélation positive indique que plus un produit est en stock, plus il a de chances d'être vendu.

Prix & ventes : Une corrélation négative suggère que les prix plus bas entraînent généralement plus de ventes.

Stock & prix : Une faible corrélation négative signifie que les produits chers ne sont pas nécessairement surstockés.

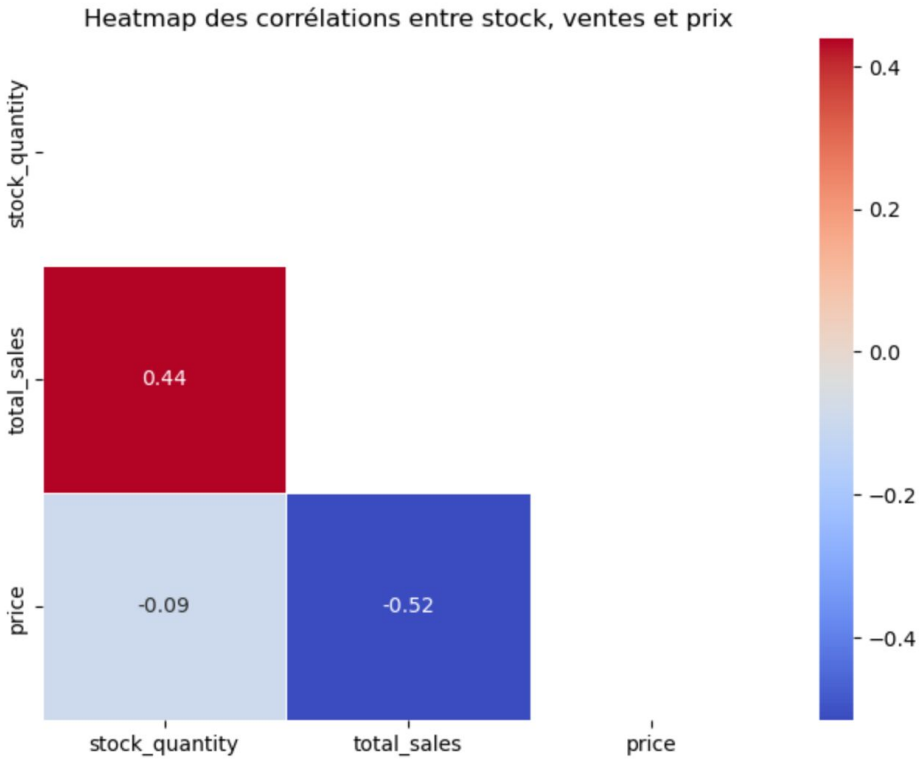

Améliorations à apporter aux fichiers de l’entreprise

-3 produits du fichier erp sont renseignés comme négatif mais au vu de leur chiffre comparé à leur valeur d’achat, on peut supposer qu’il s’agit d’une erreur de saisie et que les chiffres sont positifs.

-Lever le doute sur les 2 produits avec des stocks négatifs avec un qui se trouve sur le site et un autre qui n’y figure pas

-Ajouter les 91 produits sur le site afin d’augmenter le chiffre d’affaires et de la faire se rapprocher de la valorisation des stocks

-Se renseigner sur le produit avec un prix d’achat nettement supérieur aux prix de vente